

Econometría I

Propiedades inferenciales



Carlos A. Yanes | Departamento de Economía | 2024-02-14





Preguntas de la sesión anterior?

Variables: Clasificación básica

Variable aleatoria: Aquella que toma un **valor** numérico y su resultado esta determinado por un **Experimento**. Suelen escribirse con letras (X, Y, Z) y sus resultados se hacen con minúsculas (x, y, z) .

Un **ejemplo**: cuando se lanza un dado, X viene a ser el número de veces que lo lanzamos, entonces:

$X = \{1, 2, 3, \dots, 6\}$ y (x) puede ser 4.



Variables: Clasificación básica

```
set.seed(123) # La opción de 1 es para una solo lanzamiento (resultado)  
sample(1:6, 1)
```

```
#> [1] 3
```

Ya si quisieramos lanzar dos dados, tendríamos:

```
set.seed(123) # Ahora queremos ver dos resultados  
sample(1:12, 2)
```

```
#> [1] 3 12
```

Variables: Clasificación básica

Para el caso del lanzamiento de una moneda:

$$X = \begin{cases} 1 & = \text{Si es cara} \\ 0 & = \text{Si es sello} \end{cases}$$

- La moneda tiene dos posibles **resultados**, *posiblemente encontramos la probabilidad de que la variable tome el valor de 1 si es cara con probabilidad 0.5. Al igual que si sale sello. Ej:*

$$P(X = 1) = 0.5 \text{ y por otro lado } P(X = 0) = 0.5$$

```
set.seed(123) # Garantizar el sorteo  
sample(c("Cara", "Sello"), 1)
```

```
#> [1] "Cara"
```

Variables: Clasificación básica

- **Variables discretas:** Son aquellas que provienen de una naturaleza aleatoria o *resultado* aleatorio. Toman valores discreto de forma tal que $X : \{0, 1, 2, 3, \dots, 245\}$

```
# Definir la función para simular un sorteo de números discretos
simulacion <- function(n, min_valor, max_valor) {
  resultado <- sample(min_valor:max_valor, n, replace = TRUE)
  return(resultado)
}
# Vamos a simular un sorteo de 10 números discretos entre 1 y 100
resultado <- simulacion(10, 1, 100)
print(resultado)
```

```
#> [1] 79 51 14 67 42 50 43 14 25 90
```

- **Variables continuas:** Aquellas que toman valores en un conjunto continuo de posibles valores. P.e.: 12.32; 114, 6

```
set.seed(123)
runif(n = 10, min = 15, max = 242)
```

```
#> [1] 80.28010 193.94527 107.83776 215.44495 228.48607 25.34133 134.87995
#> [8] 217.57912 140.17575 118.65154
```

Variables: Clasificación básica

Distribución



Distribución de probabilidad

Conceptos

- La **distribución de probabilidad** es una **relación** de todos los posibles valores que son posibles resultados de una variable.
- La **probabilidad** de los sucesos suele calcularse a partir de una distribución de probabilidad.
- La **distribución acumulada de probabilidad** resulta ser la probabilidad de que la V.A sea menor o igual a un valor concreto.

| Probabilidad de ocurrencia | Resultados | | | |
|------------------------------|------------|-----|------|------|
| | 0 | 1 | 2 | 3 |
| Distribución de probabilidad | 0.6 | 0.2 | 0.16 | 0.04 |
| Distribución Acumulada | 0.6 | 0.8 | 0.96 | 1 |

Recuerde 🤖

- De la ecuación y frontera de probabilidad

$$p_i = P(X = x_i), \quad i = 1, 2, 3, \dots, k$$

Donde,

$$0 \leq p_i \leq 1$$

- La función de **densidad** reúne toda la información acerca de los valores de X y sus probabilidades correspondientes:

$$f(x_i) = p_i, \quad i = 1, 2, 3, \dots, k$$

Distribución de una variable aleatoria discreta


- Una **función de densidad discreta**, es $f(x)$ una *lista* de las probabilidades asociadas a diferentes realizaciones, x , que pueda tomar una variable discreta X :

$$P(W = w) : \begin{cases} \frac{1}{6} & \text{si } w = 1 \\ \frac{1}{6} & \text{si } w = 2 \\ \frac{1}{6} & \text{si } w = 3 \\ \frac{1}{6} & \text{si } w = 4 \\ \frac{1}{6} & \text{si } w = 5 \\ \frac{1}{6} & \text{si } w = 6 \\ 0 & \text{si ocurre otro evento} \end{cases}$$

- El valor esperado del dado es:

$$E(W) = 1 \times \frac{1}{6} + 2 \times \frac{1}{6} + 3 \times \frac{1}{6} + 4 \times \frac{1}{6} + 5 \times \frac{1}{6} + 6 \times \frac{1}{6} = 3.5$$

Ejemplo de distribución discreta



Distribución de una variable aleatoria continua

- Una **función de densidad continua** es, $f(x)$, una función asociada a una variable continua X , de tal forma que:

$$\int_a^b f(x)dx = P(a \leq x \leq b)$$

Donde $f(x)$ debe cumplir:

- $f(x) \geq 0$.
- $\int_{-\infty}^{\infty} f(x)dx = 1$


Esto permite conocer la probabilidad de que una V.A.C se encuentre en un intervalo.

Ejemplo: Distribución Continua

|||| Una **empresa** después de haber realizado un estudio de la distribución del consumo de gasolina, encontró que:

$$f(x) = \begin{cases} \frac{1}{40000} & \text{si } 10000 \leq x \leq 50000 \\ 0 & \text{si ocurre lo contrario} \end{cases}$$

(x) viene a ser la **cantidad** de gasolina que consumen sus empleados en un mes.



Preguntas al público 🏆

Qué pasaría si quiero conocer:

1. La probabilidad que los empleados consuman en este mes exactamente 30000 litros de gasolina
2. Por lo menos 30000 litros
3. Entre 20000 y 30000 litros de gasolina

Para esto:

Resuelvo la integral de la **función**:

$$\int f(x)dx = \int \frac{1}{40000} dx = \frac{x}{40000} + C$$

Para la *pregunta 1* \Rightarrow

$$P(X = 30000) = P(30000 \leq x \leq 30000)$$

$$\int_{30000}^{30000} f(x)dx = 0$$

Es decir, la probabilidad que consuman 30 mil litros de gasolina es exactamente cero.



```
fp <- function(x){1/40000}  
Vfp <- Vectorize(fp) # Se debe aplicar  
e1 <- integrate(Vfp, lower = 30000, upper = 30000)$value  
e1
```

```
#> [1] 0
```

Continuando:

Para la *pregunta 2* \Rightarrow

$$P(X \geq 30000) = 1 - P(10000 \leq x \leq 30000)$$

$$1 - \int_{10000}^{30000} f(x)dx = 1 - 0.5 = 0.5$$

La probabilidad es del 50% en este caso de que al menos consuman 30 mil litros.

De donde salió el **0.5**? 🤔

$$\int_{10000}^{30000} \frac{30000}{40000} - \frac{10000}{40000} = \frac{2}{4} = 0.5$$



```
e2 <- 1 - integrate(Vfp, lower = 10000, upper = 30000)$value  
e2
```

```
#> [1] 0.5
```

Para lo último

Para la *pregunta 3* \Rightarrow

$$P(20000 \leq X \leq 30000) = P(20000 \leq x \leq 30000)$$

$$\int_{20000}^{30000} f(x) dx = 0.25$$

La probabilidad es del 25% en este caso de que al consuman entre 20 mil y 30 mil litros de gasolina.

De donde:

$$\int_{20000}^{30000} \frac{30000}{40000} - \frac{20000}{40000} = \frac{1}{4} = 0.25$$

```
e3 <- integrate(Vfp, lower = 20000, upper = 30000)$value  
e3
```

```
#> [1] 0.25
```

Operadores



Operador: Sumatoria

Simplifica de forma significativa el uso de términos en una expresión.

$$M_1 + M_2 + M_3 + M_4 + M_5 + M_6 + M_7$$

Entonces podemos escribir lo anterior como:

$$\sum_{i=1}^7 M_i$$

Calcule el *resultado* de la siguiente expresión:

$$\sum_{j=0}^2 \frac{1}{(j+1)(j+3)}$$

El desarrollo es sencillo:

$$\sum_{j=0}^2 \frac{1}{(j+1)(j+3)} = \frac{1}{1 \cdot 3} + \frac{1}{2 \cdot 4} + \frac{1}{3 \cdot 5} = \frac{40 + 15 + 8}{120} = \frac{63}{120}$$

Propiedades Operador Sumatoria

Algunas de las principales:

1.
$$\sum_{i=1}^n (a_i + b_i) = \sum_{i=1}^n a_i + \sum_{i=1}^n b_i \quad \text{Prop. aditiva}$$

2.
$$\sum_{i=1}^n c a_i = c \sum_{i=1}^n a_i \quad \text{Prop. de homogeneidad}$$

3. Una propiedad que es importante:

$$\sum_{i=1}^n c = n c ; \text{ Prop. Constante}$$

Por ejemplo: $\sum_{i=1}^4 7 = 7 + 7 + 7 + 7 = 28$

Operador Productoria

Es **análogo** al operador **sumatoria**. Se plantea como lo siguiente:

$$\prod_{i=1}^n a_i = a_1 \times a_2 \cdots a_n$$

Por ejemplo:

$$\prod_{i=2}^4 (3i - 2) = 4 \times 7 \times 10 = 280$$

Pequeño ejemplo en

Con el software, es fácil de implementar las operaciones anteriores ya sea con los comandos `sum` o `prod`.

- Halle la sumatoria y el producto de $a = 35$ donde $i : \{1, 2, 3, 4, 5\}$

$$\sum_{i=1}^5 a_i, \text{ ademas de la } \prod_{i=1}^5 a_i$$

```
a<-rep(35,5)
a
```

```
#> [1] 35 35 35 35 35
```

```
sum(a)
```

```
#> [1] 175
```

```
prod(a)
```

```
#> [1] 52521875
```

Otro ejemplo en

- Para la función

$$\prod_{i=2}^4 (3i - 2)$$

- Halle el respectivo **resultado**

De forma manual es:

$$(3)(2) - 2 \times (3)(3) - 2 \times (3)(4) - 2 = 280$$

- En  construiremos la formula haciendo uso de las **funciones**, para eso podemos decirle al programa que usaremos el *comando* function.

Funciones

Una función **R**, permite obtener un resultado a partir de una formula anteriormente establecida y tiene varias partes:

Primero hagamos un ejemplo simple de establecer la formula de raíz cuadrada de un valor o número

```
raiz =  
  function(x) {  
    raiz_x = x^(1/2) # formula que se va establecer  
    return(raiz_x) ## Resultado  
  }
```

A continuación la usamos con el valor de 144

```
raiz(144)
```

```
#> [1] 12
```

Funciones

Podemos además implementar otras opciones como las listas o la manera en como quiere que nos quede el resultado:

```
raiz =  
  function(x) {  
    raiz_x = x^(1/2) # formula que se va establecer  
    return(list(valor=x, raiz_cuadrada=raiz_x))  
  }
```

Testeamos

```
raiz(144)
```

```
#> $valor  
#> [1] 144  
#>  
#> $raiz_cuadrada  
#> [1] 12
```

Funciones

Tambien se puede con el formato tibble de tidyverse y colocar como si se tratara de una matriz.

```
raiz =  
  function(x) {  
    raiz_x = x^(1/2) # formula que se va establecer  
    df = tibble(valor=x, raiz_cuadrada=raiz_x) # un dataframe  
    return(df)  
  }
```

Testeamos

```
raiz(144)
```

```
#> # A tibble: 1 × 2  
#>   valor raiz_cuadrada  
#>   <dbl>         <dbl>  
#> 1   144             12
```

El resultado aparece como si fuera una tabla

Funciones

Para el caso de

$$\prod_{i=2}^4 (3i - 2)$$

```
caps<-function(x,y){a=3*(x:y)-2;m=prod(a);m}  
# Los argumentos son X y Y, y es donde empieza y termina la productoria.  
caps(2,4) # con la función
```

```
#> [1] 280
```

Note que para este caso usamos (;) para separar por operación

Media y varianza de una distribución



Media y varianza de una distribución

Para el caso general -esto es- para X_i , i.i.d para cualquier distribución:

$$\text{Media: } E(X) = \bar{X} = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \sum_{i=1}^n \mu_x = \mu_x$$

Para la **Varianza** \Rightarrow

$$\begin{aligned} \text{Varianza: } &= \text{var}(\bar{X}) \\ &= E[\bar{X} - E(\bar{X})]^2 \\ &= E\left[\left(\frac{1}{n} \sum_{i=1}^n X_i\right) - \mu_x\right]^2 \\ &= E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \mu_x)\right]^2 \end{aligned}$$

Covarianza



Covarianza

Una de las medidas que muestra como evolucionan dos variables.

$$\text{cov}(X, Y) = \sigma_{xy} = E[(X - \mu_x)(Y - \mu_y)]$$

▲ Lo que vendría a ser:

$$\sum_{i=1}^k \sum_{j=1}^l (x_j - \mu_x)(y_i - \mu_y) \text{Pr}(X = x_j, Y = y_i)$$

El signo de la covarianza es fundamental!!

▲ Esto significa:

- **La dirección de la influencia de una variable sobre la otra.**

```
x <- c(4.2, 4.6, 3.8, 4.1, 4.3) # Datos de una asignatura
y <- c(2.1, 2.4, 2.8, 2.1, 3.2) # Datos segunda asignatura
covarianza_xy <- cov(x, y) # Formula base
print(covarianza_xy)
```

```
#> [1] -0.0125
```

Correlación

Debido a que la covarianza presenta dificultades en la interpretación dado el producto de las dispersiones de variables de Y y X. Surge el concepto o medida de dependencia entre Y y X y resuelve el problema de interpretación.

$$Corr(X, Y) = \frac{cov(X, Y)}{\sqrt{var(x)var(y)}} = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$

🔧 La medida esta en un intervalo cerrado

$$-1 \leq corr(X, Y) \leq 1$$

```
correlacion_xy <- cor(x, y) # Formula correlación  
print(correlacion_xy)
```

```
#> [1] -0.08998863
```

Coeficiente de Correlación

Dado que la **Covarianza** depende de las unidades en que se miden las desviaciones, aparece un concepto mas estandarizado a la hora de medir relación y asociación entre un par de variables **aleatorias** y tener un concepto o interpretación mas "detallada".

Es un **estadístico** que mide la relación (**signo**) y la fuerza (**magnitud**) de asociación lineal entre dos variables.


❗ La formula puede ser *re-expresada* como:

$$\frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Interpretación

A El coeficiente (**r**) no tiene unidades y solo puede tomar valores entre -1 y 1, lo que es $-1 \leq r_{x,y} \leq 1$. **Su interpretación depende del signo y magnitud que nos arroja el estadístico.**

- Cuando $Corr(X, Y) = 1$, se dice que hay una asociación lineal perfecta y directa.
- Cuando $Corr(X, Y) = 0$, se dice que NO hay asociación.
- Cuando $Corr(X, Y) = -1$, se dice que hay una asociación lineal perfecta e indirecta.



Recuerde 🤖

Propiedades en Varianza

La suma de varianzas X e Y toma la expresión:

$$\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y) = \sigma_x^2 + \sigma_y^2 + 2\sigma_{xy}^2$$

Y dado el caso que las variables sean **independientes** la formula se reduce a:

$$\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y) = \sigma_x^2 + \sigma_y^2$$

Independencia lineal

🔏 Dos variables *aleatorias*, X y Y, se consideran independientes si y solamente si:

$$E[XY] = E[X]E[Y]$$

- Esto no implica que no existe relación entre ellas

Nuevamente lo de distribución




Recordeis

Recordemos que utilizamos **funciones de densidad de probabilidad** (FDP) para describir la probabilidad de que una **variable aleatoria continua** tome un rango de valores, p.e: (El área total = 1). Estas *FDP* caracterizan las distribuciones de probabilidad, y las distribuciones más comunes/famosas/populares reciben nombres (*p.e.*, normal, *t*, Weibull, Gamma, Poisson).

- La probabilidad de que una variable aleatoria normal estándar tome un valor entre -2 y 0:


$$P(-2 \leq X \leq 0) = 0.48$$



Recordeis

- Para el caso de hallar la probabilidad de que una variable aleatoria normal estándar tome un valor mayor a 2:

$$P(X > 2) = 0.023$$



En 

```
prob <- 1- pnorm(2)
prob
```

```
#> [1] 0.02275013
```

Distribución Normal

Normal estándar: Su forma concisa de expresión es $N(\mu, \sigma^2)$. Lo que significa que su media, $\mu = 0$ y su varianza $\sigma^2 = 1$. Para buscar probabilidades de una variable normal se debe **estandarizar** la variable en cuestión restando su **media** y luego dividir el resultado por la **desviación típica**.

✈ **Ejemplo:** Suponga que desea calcular la probabilidad de que $Y \leq 2$? cuando $N \sim (1, 4)$.

- Para eso simplemente aplica:

$$Pr(Y \leq 2) = \frac{Y - 1}{2} \Rightarrow \frac{2 - 1}{2} = \Phi(0.5) = 0.691$$

▲ *La formula de la normal es:*


$$\text{Normal} = \frac{X - \mu}{\sigma}$$

- Donde X es el valor a *testear*; μ es la media de la **distribución** y σ la *desviación estandar*.

❗ **Mucho cuidado!!:** El signo u operador de Φ significa que hay que ir a buscar el valor en la **tabla de la Normal**.

Ejemplo de valor en tabla normal

FUNCIÓN DE DISTRIBUCIÓN NORMAL $N(0,1)$




| z | 0,00 | 0,01 | 0,02 | 0,03 | 0,04 | 0,05 | 0,06 | 0,07 | 0,08 | 0,09 |
|-----|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 0,0 | 0,5000 | 0,5040 | 0,5080 | 0,5120 | 0,5160 | 0,5199 | 0,5239 | 0,5279 | 0,5319 | 0,5359 |
| 0,1 | 0,5398 | 0,5438 | 0,5478 | 0,5517 | 0,5557 | 0,5596 | 0,5636 | 0,5675 | 0,5714 | 0,5753 |
| 0,2 | 0,5793 | 0,5832 | 0,5871 | 0,5910 | 0,5948 | 0,5987 | 0,6026 | 0,6064 | 0,6103 | 0,6141 |
| 0,3 | 0,6179 | 0,6217 | 0,6255 | 0,6293 | 0,6331 | 0,6368 | 0,6406 | 0,6443 | 0,6480 | 0,6517 |
| 0,4 | 0,6554 | 0,6591 | 0,6628 | 0,6664 | 0,6700 | 0,6736 | 0,6772 | 0,6808 | 0,6844 | 0,6879 |
| 0,5 | 0,6915 | 0,6950 | 0,6985 | 0,7019 | 0,7054 | 0,7088 | 0,7123 | 0,7157 | 0,7190 | 0,7224 |
| 0,6 | 0,7257 | 0,7291 | 0,7324 | 0,7357 | 0,7389 | 0,7422 | 0,7454 | 0,7486 | 0,7517 | 0,7549 |
| 0,7 | 0,7580 | 0,7611 | 0,7642 | 0,7673 | 0,7704 | 0,7734 | 0,7764 | 0,7794 | 0,7823 | 0,7852 |

En  es hacer uso del comando `pnorm()`, observe:

```
pnorm(0.5)
```

```
#> [1] 0.6914625
```

Grafico de nuestro ejemplo (normalizada)



La probabilidad de $P(x \leq 2) = P(Z \leq 0.5)$ con una media de 1 y varianza de 4 es del 69%.

Clave

Sean X_1 y X_2 dos números tal que $X_1 < X_2$

- Es bueno saber que hay que usar lo siguiente normalmente:

$$Pr(Y \leq X_2) = Pr(Z \leq d_2) = \Phi(d_2)$$

- **Es posible que ocurra o le pregunten de esto**

$$Pr(Y \geq X_1) = Pr(Z \geq d_1) = 1 - \Phi(d_1)$$

- O también pase 


$$Pr(X_1 \leq Y \leq X_2) = Pr(d_1 \leq Z \leq d_2) = \Phi(d_2) - \Phi(d_1)$$

- No olvide que:

$$d = \frac{X_1 - \mu}{\sigma}$$

Mas ejemplos


✈ **Ejemplo:** Suponga que desea calcular la probabilidad de una variable aleatoria cuando $P(-1.96 \leq Y \leq 1.96) = 0.95$.



```
probabilidad <- pnorm(1.96) - pnorm(-1.96)
probabilidad
```

```
#> [1] 0.9500042
```

Otras distribuciones



Las distintas distribuciones son importantes a la hora de hacer inferencia y pruebas de hipótesis y de **parámetros de los modelos**.

Y todo esto para qué? 🐱

Estimador

Se considera como una variable aleatoria que posee las características de ser *Insesgado*, *Mínima Varianza* y *Eficiente*.

- Sea L una variable aleatoria en función de unas características tales como:

$$L = f(X_1, X_2, X_3, \dots, X_n)$$

$$E(L) = \beta$$

Sesgo del estimador:

$$E(L) - \beta = 0$$

- ❗ Nuestros estimadores muestrales, deben ser similares a nuestros estimadores poblacionales.

Estimación econométrica

Tenemos presente una ecuación econométrica:


$$Y_i = \beta_0 + \beta_1 X_i + \mu_i$$

- La ecuación tiene como objeto "modelar" la interacción de variables.
- La estadística es lo que permite validar estas estimaciones paramétricas.

Parámetro


En nuestras ecuaciones lo tendremos como: $P = \{\beta, \alpha, \gamma, \theta, \dots, \omega\}$ y lo tendremos como aquel valor de medida de cambio del efecto de una variable explicativa sobre la dependiente. *Función de datos que permite obtener estimaciones de los parámetros desconocidos.*

El estimador deseable




Sesgos del estimador

Estimador insesgado: $E[\hat{\beta}] = \beta$



Estimador sesgado: $E[\hat{\beta}] \neq \beta$



Y el asunto de la varianza en estimadores 🙈


Mínima Varianza

Las tendencias centrales (medias) de las distribuciones en competencia no son lo único que importa. También nos importa la **varianza** de un estimador.

$$\text{Var}(\hat{\beta}) = E[(\hat{\beta} - E[\hat{\beta}])^2]$$

Los estimadores de menor varianza significan que obtenemos estimaciones más cercanas a la media en cada muestra.

Mínima Varianza



Mínima Varianza

- Siempre hay una especie de **trade-off** entre sesgo y varianza.
- Para el caso de **Econometría** la preferencia ahonda la parte de insesgadez (consistencia).
- En otras partes... Ya va por el lado de lo que les sirve.. sin embargo hacen hincapie en la varianza.

Bibliografía

- ☞ Álvarez, R. A. R., Calvo, J. A. P., Torrado, C. A. M., & Mondragón, J. A. U. (2013). *Fundamentos de econometría intermedia: teoría y aplicaciones*. Universidad de los Andes.
- ☞ Stock, J. H., Watson, M. W., & Larrión, R. S. (2012). *Introducción a la Econometría*.
- ☞ Wooldridge, J. M. (2015). *Introductory econometrics: A modern approach*. Cengage learning.

Gracias por su atención!

Alguna pregunta adicional?

Carlos Andres Yanes Guerra

 cayanes@uninorte.edu.co

 [keynes37](https://twitter.com/keynes37)