

Econometría I

Autocorrelación



Carlos Yanes | Departamento de Economía | 2023-04-19



Preguntas de la sesion anterior?

A full-page photograph of skateboarder Nyjah Huston. He is sitting on a set of wide, grey concrete stairs. He is wearing a black t-shirt, black pants, white sneakers, and a black baseball cap with a yellow logo. He has visible tattoos on both arms. His hands are clasped in his lap. To his right, a skateboard with a colorful graphic deck is standing vertically on the stairs. The background is a dark, textured wall. On the left, a large, metallic, curved structure, possibly part of a ramp or staircase, is visible. On the right, a bright green metal railing is partially seen.

NYJAH HUSTON

Antes de empezar ! ...



Recordéis

<u>P-VALUE</u>	<u>INTERPRETATION</u>
0.001	HIGHLY SIGNIFICANT
0.01	
0.02	
0.03	
0.04	SIGNIFICANT
0.049	
0.050	OH CRAP. REDO CALCULATIONS.
0.051	ON THE EDGE OF SIGNIFICANCE
0.06	
0.07	HIGHLY SUGGESTIVE, SIGNIFICANT AT THE $P < 0.10$ LEVEL
0.08	
0.09	
0.099	HEY, LOOK AT THIS INTERESTING SUBGROUP ANALYSIS
≥ 0.1	



Antes del arranque...



1. Este curso tiene siempre **teoría** por aprender.
2. Tendrá ventajas sobre los demás que hacen data science si conoce o sabe de esto.
3. Los últimos test que hemos estado aprendiendo no son nada **fáciles**, requieren de saber **interpretar** los resultados de estos y del como esta planteada la **prueba de hipótesis nula**.

Autocorrelación



Autocorrelación

⚠ Note un modelo de corte transversal:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$$

- Donde $i \rightarrow N$

📖 Ahora uno de **series de tiempo**:

$$Y_t = \beta_0 + \beta_1 X_{1t} + \beta_2 X_{2t} + u_t$$

- Donde $t \rightarrow T$

Las **series de tiempo** a diferencia de los cortes transversales (diferentes por individuos) difieren o varían por periodos de tiempo.

Ejemplo

- 📍 Nos enfocamos en una **unidad/individuo** p.e: Colombia
- 📅 Lo observamos varias veces en el **tiempo** p.e: Colombia: 2015-2025

Autocorrelación: Series de Tiempo

Tiempo	Observaciones
2017	125
2018	451
2019	378
2020	391
2021	115

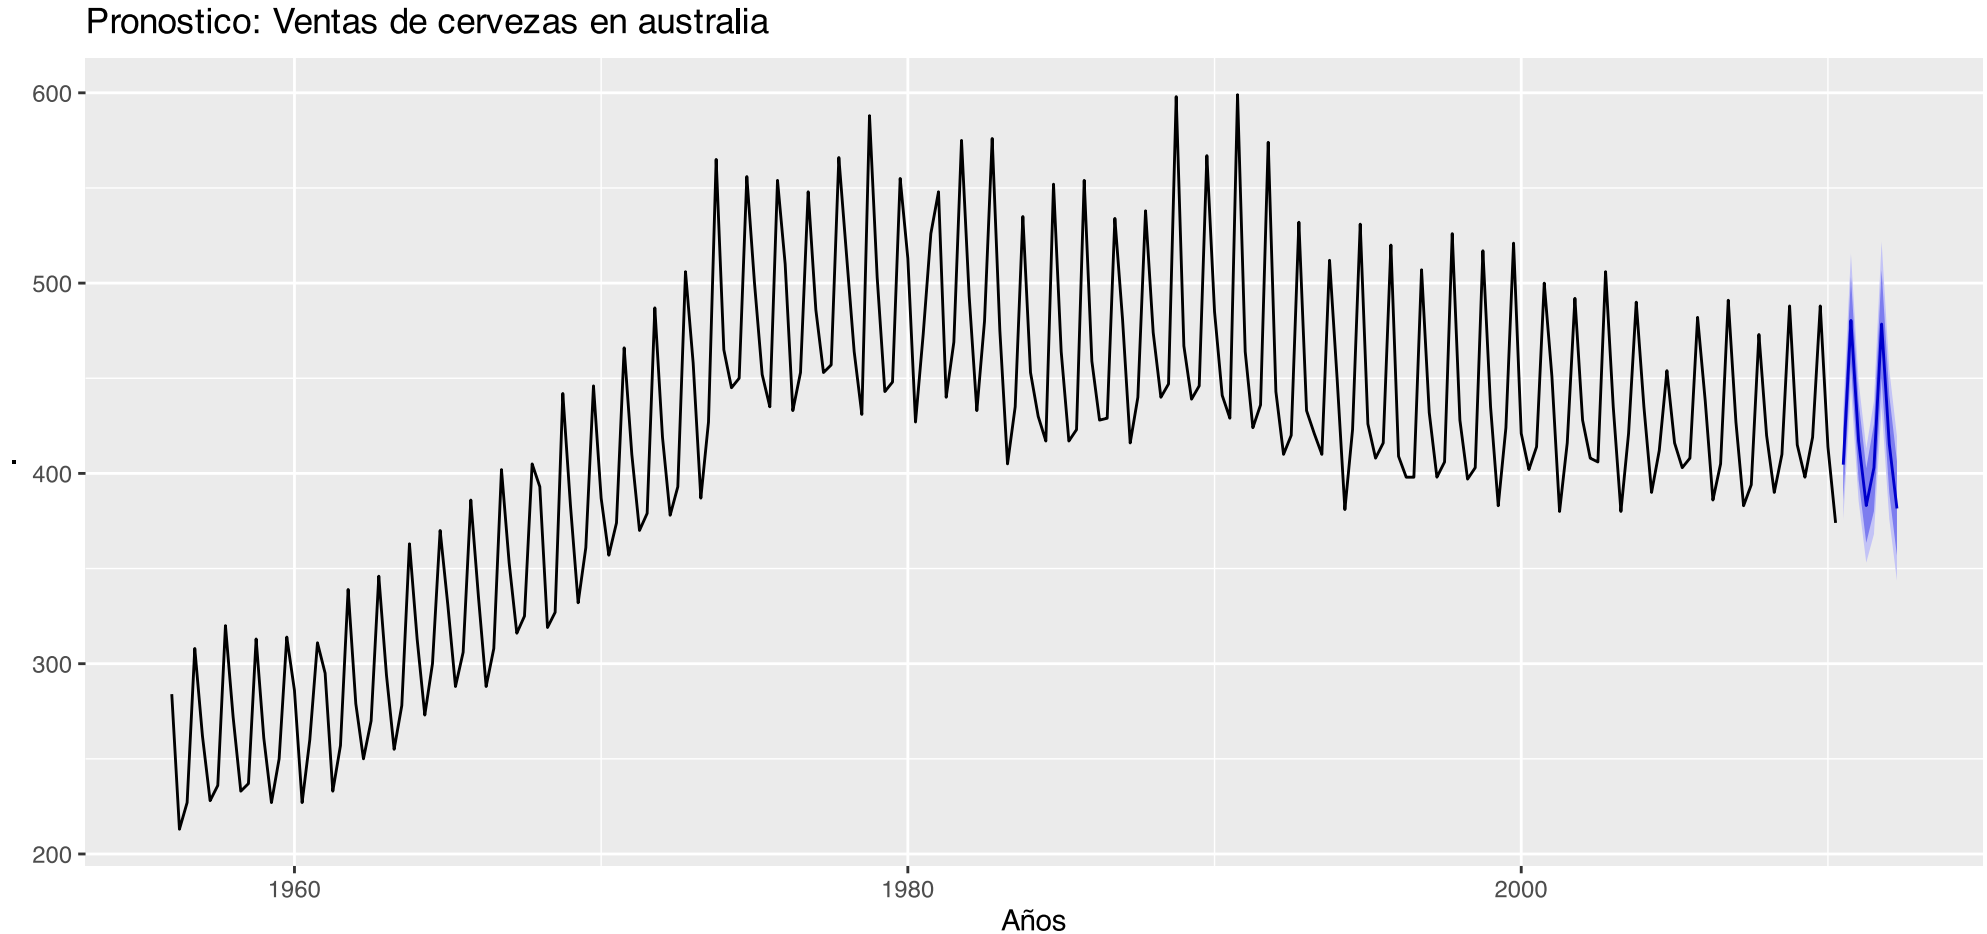
En una **serie de tiempo** los reportes deben ir organizados por un **índice** que debe variar en el tiempo.

- Para series con frecuencia mas desagregadas *p.e*: (mes, trimestre, semestre) habría que usar en **R** la opción de frequency:

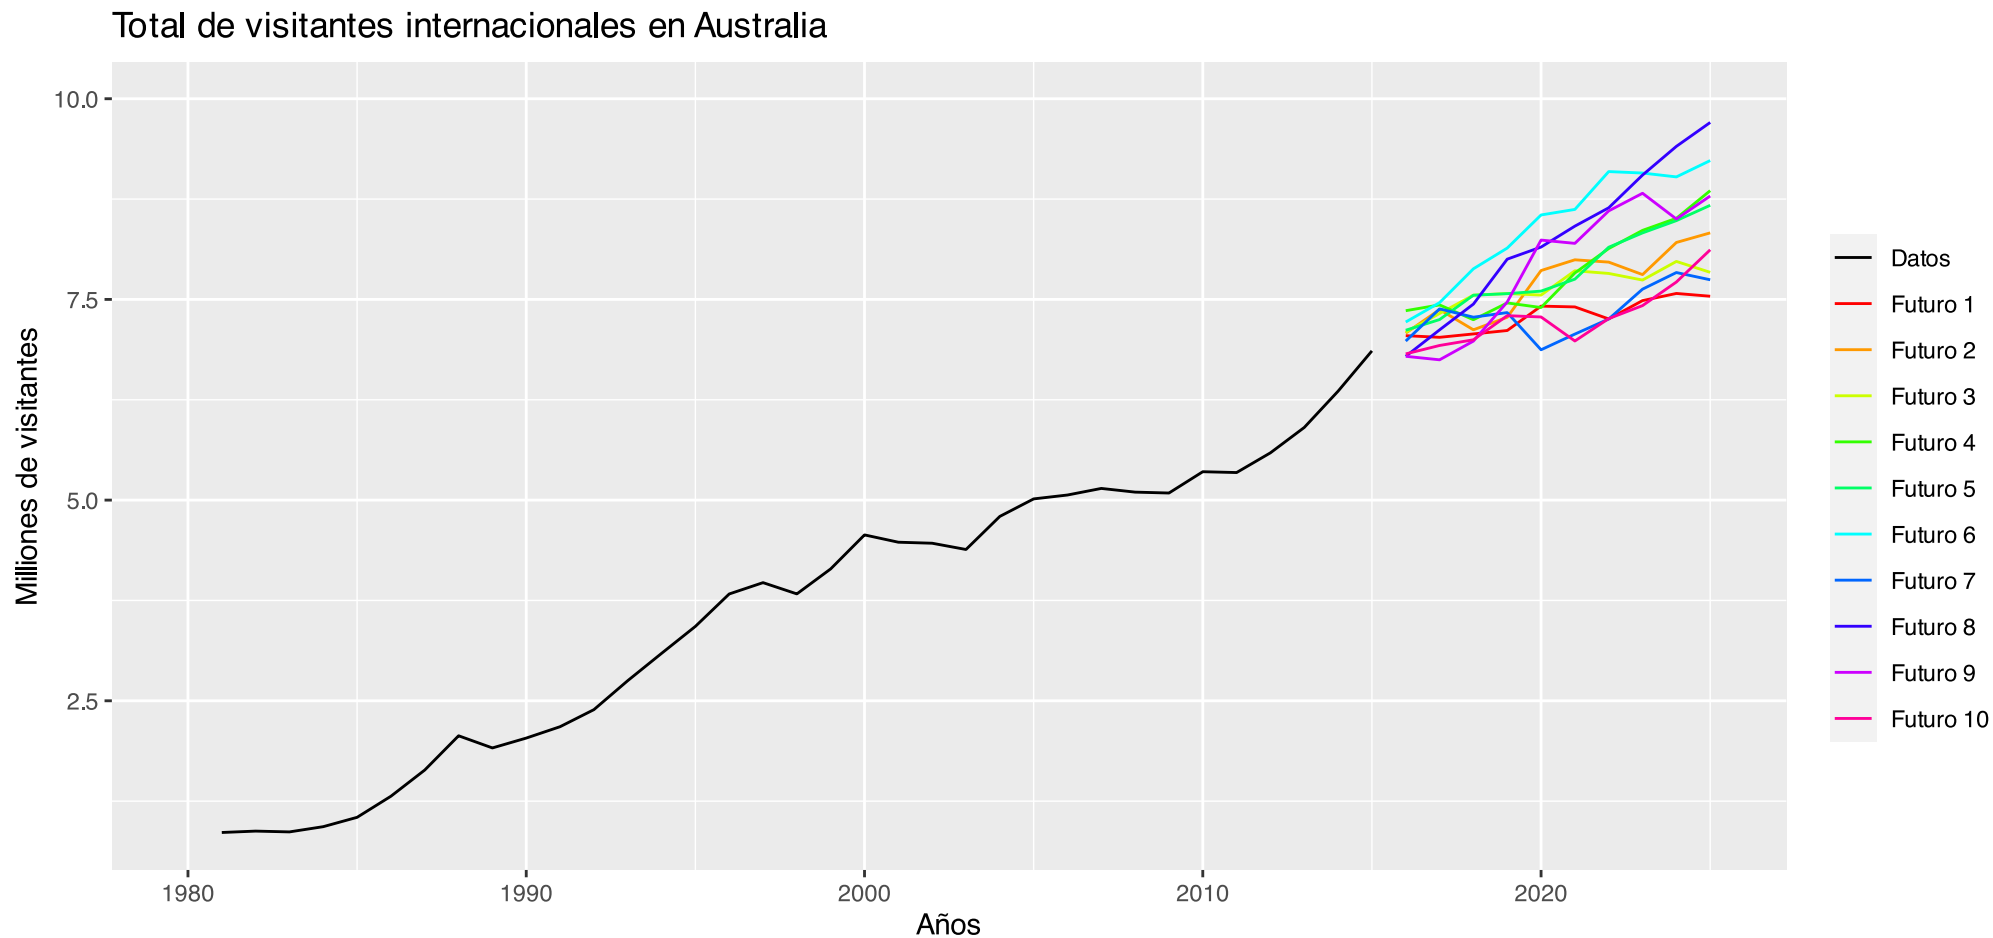
```
y <- ts(datos, frequency=12, start=c(2010, 1))
```

- *Donde 12 es la parte de frecuencia mensual y en la parte de start el año y mes donde inicia la serie.*

Autocorrelación: Series de Tiempo




Autocorrelación: Series de Tiempo



Autocorrelación: Series de Tiempo

Gráfico Estacional: Venta de drogas antidiabeticos



Modelos MCO



Autocorrelación: Tipo de Modelos MCO

Nuestro modelo inicial puede ser:

$$\text{Consumo}_t = \beta_0 + \beta_1 \text{Ingreso}_t + u_t$$

O tal vez

$$\text{Consumo}_t = \beta_0 + \beta_1 \text{Ingreso}_t + \beta_2 \text{Ingreso}_{t-1} + u_t$$

Incluso puede ser

$$\text{Consumo}_t = \beta_0 + \beta_1 \text{Ingreso}_t + \beta_2 \text{Ingreso}_{t-1} + \beta_3 \text{Consumo}_{t-1} + u_t$$

- Las **series** pueden ser **estáticos**, un momento (t) en particular
- Y de otra forma **dinámicos**, que ya incluyen choques que afectan el futuro de la **serie**.

Autocorrelación: Tipo de Modelos MCO

Concepto

Autocorrelación: ocurre cuando nuestras *perturbaciones* están correlacionadas en el tiempo, *p.e*:

$$\text{Cov}(u_t, u_j) \neq 0 \text{ para } t \neq j$$

Otra forma de pensar: Si el choque de la perturbación (t) se correlaciona con las perturbaciones "cercanas" en $(t - 1)$ y $(t + 1)$.

El término de **correlación serial** es el mismo que **Autocorrelación**

Operador rezago

Hay que estar atentos a lo que significa un **rezago**, esto es:

Tiempo	Observaciones	Rezago
2017	125	NA
2018	451	125
2019	378	451
2020	391	378
2021	115	391

Los **rezagos** o "lags" permiten medir los efectos temporales de una variable. Esto puede estar bien para (Y) pero mal para los residuos (u).

P.e.:,

$\{1, 2, 3, 4, 5, 6, 7, 8, 9\} = x$


$\{?, 1, 2, 3, 4, 5, 6, 7, 8\} = \text{lag}(x)$

$\{?, ?, 1, 2, 3, 4, 5, 6, 7\} = \text{lag}(x, 2)$

$\{?, ?, ?, 1, 2, 3, 4, 5, 6\} = \text{lag}(x, 3)$


Autocorrelación

Autocorrelación Positiva: Residuos (u_t) en el tiempo




Autocorrelación

Autocorrelación Positiva: Dependiente (y_t) en el tiempo




Autocorrelación

Autocorrelación Negativa: Residuos (u_t) en el tiempo



Autocorrelación

Autocorrelación Negativa: Dependiente (y_t) en el tiempo



Autocorrelación: Modelos Estáticos

Empecemos con un modelo muy común: un modelo de serie temporal estática cuyas perturbaciones presentan **autocorrelación de primer orden**, *conocido como AR(1)*:

$$\text{Consumo}_t = \beta_0 + \beta_1 \text{Ingreso}_t + u_t$$

Donde

$$u_t = \rho u_{t-1} + \varepsilon_t$$

Y el residuo ε_t es independiente e idénticamente distribuido (*i.i.d.*).

Para una **Autocorrelación de segundo-orden**, o **AR(2)**, puede ser

$$u_t = \rho_1 u_{t-1} + \rho_2 u_{t-2} + \varepsilon_t$$

Autocorrelación: Modelos Estáticos

Un modelo/proceso **AR(p)** tiene una estructura de perturbaciones:

$$u_t = \sum_{j=1}^p \rho_j u_{t-j} + \varepsilon_t$$

Mostrando que las perturbaciones del presente (t) están correlacionadas con sus rezagos p .

Recuerde que ρ es similar a un parámetro β solo que este se usa como si estuviera modelando a las perturbaciones (e_t)

Autocorrelación: Problemas

De forma similar a la **heterocedasticidad** tener **correlación serial** nos genera:

- MCO con estimadores **insesgados**.
- MCO los errores estandar ($S.E$) de los ($\beta's$) son **sesgados**
- MCO es **ineficiente**

■ La autocorrelación se vuelve más complicada con las variables dependiente rezagadas.

Autocorrelación: Modelo Dinámico

Considere un modelo de rezago distribuido de tal manera que:

$$\text{Consumo}_t = \beta_0 + \beta_1 \text{Ingreso}_t + \beta_2 \text{Consumo}_{t-1} + u_t$$

Donde

$$u_t = \rho u_{t-1} + \varepsilon_t$$

Problema:

Ambos Consumo_{t-1} (como regresor en el periodo t) y u_t (el residuo en t) dependen de u_{t-1} . *p.e.*, un regresor está correlacionado con el residuo contemporáneo

P: Por qué este problema?

R.: Esto viola **Exogeneidad contemporánea**, *p.e.*, $\text{Cov}(x_t, u_t) \neq 0$.

Autocorrelación: Modelo Dinámico

Para ver esto hay que escribir el modelo en t y en $t - 1$:

$$\begin{aligned}\text{Consumo}_t &= \beta_0 + \beta_1 \text{Ingreso}_t + \beta_2 \text{Consumo}_{t-1} + u_t \\ \text{Consumo}_{t-1} &= \beta_0 + \beta_1 \text{Ingreso}_{t-1} + \beta_2 \text{Consumo}_{t-2} + u_{t-1}\end{aligned}$$

Observe ahora que $u_t = \rho u_{t-1} + \varepsilon_t$.

$$\text{Consumo}_t = \beta_0 + \beta_1 \text{Ingreso}_t + \beta_2 \text{Consumo}_{t-1} + \overbrace{(\rho u_{t-1} + \varepsilon_t)}^{u_t} \quad (1)$$

$$\text{Consumo}_{t-1} = \beta_0 + \beta_1 \text{Ingreso}_{t-1} + \beta_2 \text{Consumo}_{t-2} + u_{t-1} \quad (2)$$

En (1), podemos ver que u_t depende de (esta correlacionado) u_{t-1} .

En (2), miramos entonces que Consumo_{t-1} , un regresor en (1), también con covarianza con u_{t-1} .

\therefore En síntesis, el modelo está sesgado y no es **exógeno**

Autocorrelación: Test de corrección

- Tenemos a **Breush - Pagan**
- Uno ampliamente conocido como **Durbin-Watson**

Autocorrelación: Breush-Pagan

Paso 1: Estima su modelo estático ($y_t = \beta_0 + \beta_1 x_t + u_t$) con MCO

```
modelo <- lm(y ~ x, data = base)
```

Paso 2: Agregamos residuos a la base

```
base$e <- residuals(modelo)
```

Paso 3: Estima la regresión del residuo con su rezago (**sin intercepto**)

```
mod_resid <- lm(e ~ -1 + lag(e), data = base)
```

Autocorrelación: Breush-Pagan

Paso 4: Observe el t estadístico del parámetro ($\hat{\rho}$) que es el coeficiente en el paso 3.

```
tidy(mod_resid)
```

term	estimate	std.error	statistic	p.value
lag(e)	0.973	0.0508	19.1	1.28e-17

Si la probabilidad del t valor es menor al p -value de 0.05, tendríamos que rechazar a H_0 .

La hipótesis H_0 es $H_0 : \rho = 0$, *p.e.*, es decir, no hay autocorrelación.

Paso 5: Concluimos para este caso que **existe** suficiente evidencia estadística para rechazar H_0 y por ende tenemos autocorrelación.

Autocorrelación: Breush-Pagan

Ejemplo: Modelo rezagado

Paso 1: Estimamos el modelo en rezago (1, 0) con MCO.

```
# Estimar el modelo
mco_est <- lm(
  y ~ lag(y) + x,
  data = base
)
# Resumen
tidy(mco_est)
```

term	estimate	std.error	statistic	p.value
(Intercept)	-3.85e-10	2.78e-10	-1.38	0.179
lag(y)	1.02	1.21e-15	8.42e+14	0
x	-1.84e-16	1.97e-16	-0.934	0.359

Autocorrelación: Breush-Pagan

Ejemplo: Modelo rezagado


Paso 2: Guardamos los residuos de ese modelo

```
# Guardar residuos  
base$ebg <- c(NA, residuals(mco_est))
```

Nota: Colocamos la parte de NA porque el primer rezago desaparece (*valor perdido*).

Autocorrelación: Breush-Pagan

Ejemplo: Modelo rezagado



Autocorrelación: Breush-Pagan

Ejemplo: Modelo rezagado

Paso 3: Regresión de los residuos con un intercepto, variables explicativas, y residuos rezagados.

```
# BG reg  
bg_mod <- lm(  
  ebg ~ lag(y) + x + lag(ebg) + lag(ebg, 2),  
  data = base  
)
```

	Estimate	Standard Error	t value	Pr(> t)
(Intercept)	0.000	0.000	1.768	0.0909 .
lag(y)	-0.000	0.000	-1.743	0.0953 .
x	0.000	0.000	1.702	0.1029
lag(ebg)	0.094	0.197	0.479	0.6366
lag(ebg, 2)	-0.039	0.087	-0.441	0.6633

Signif. codes: 0 <= '*' < 0.001 < ' ' < 0.01 < '*' < 0.05 < '.' < 0.1 < ' ' < 1

Residual standard error: 1.731e-11 on 22 degrees of freedom

Autocorrelación: Breush-Pagan

Ejemplo: Modelo rezagado

Paso 4: Prueba F (o LM) Para probar si $\rho_1 = \rho_2 = 0$.

Recuerde: Debemos usar la prueba F , nos permite moldear de esta forma las hipótesis (Mire: $\rho_1 = \rho_2 = 0$)

$$F_{q, n-p} = \frac{(\text{SRC}_r - \text{SRC}_{nr}) / q}{\text{SRC}_{nr} / (n - p)}$$

Donde q es el número de restricciones y p es el número de parámetros del modelo *no restringido* (incluyendo el intercepto).

Podemos usar la función de `waldtest()` del paquete `lmtest` de R para esto.

Autocorrelación: Breush-Pagan

Ejemplo: Modelo rezagado

Paso 4: Prueba F (o LM) Para probar si $\rho_1 = \rho_2 = 0$.

```
# BG regresion
bg_mod <- lm(
  ebg ~ lag(y) + x + lag(ebg) + lag(ebg, 2),
  data = base
)
# Usamos el test
p_load(lmtest)
waldtest(bg_mod, c("lag(ebg)", "lag(ebg, 2)"))
```

Aquí, estamos implementando la opción de `waldtest` para probar

- La especificación del modelo `bg_mod` (nuestro **modelo no restringido**)
- Contra un modelo sin los términos `lag(ebg)` y `lag(ebg, 2)` (nuestro **modelo restringido**)

Autocorrelación: Breush-Pagan

Ejemplo: Modelo rezagado

Paso 4: Prueba F (o LM) Para probar si $\rho_1 = \rho_2 = 0$.

```
# BG regresion
bg_mod <- lm(
  ebg ~ lag(y) + x + lag(ebg) + lag(ebg, 2),
  data = base
)
# Usamos el test
p_load(lmtest)
waldtest(bg_mod, c("lag(ebg)", "lag(ebg, 2)"))
```

Res.Df	Df	F	Pr(>F)
22			
24	-2	0.399	0.676

Autocorrelación: Breush-Pagan

Ejemplo: Modelo rezagado

Paso 5: Conclusiones

Con un p -value de ~ 0.676 , **No rechazamos la hipótesis nula.**

- No podemos rechazar que $\rho_1 = \rho_2 = 0$.
- No podemos rechazar la "no autocorrelación" en el modelo.

Sin embargo, **Vamos a testear también la autocorrelación de orden:** AR(2).

Podemos obtener diferentes respuestas con diferentes pruebas.

El p -value para el AR(1) es 0.0178—que sugiere una autocorrelación de primer orden *este modelo es para una econometría mas avanzada.*

Autocorrelación: Durbin-Watson


Es la mas conocida para encontrar autocorrelación.

- Asume que $\mu_t = \rho\mu_{t-1} + \epsilon_t$ y sigue una distribución asintótica.
- La formula del estadístico es:

$$d = \frac{\sum_{t=2}^T (\mu_t - \mu_{t-1})^2}{\sum_{t=1}^T \mu_t^2}$$

- El estadístico DW, se puede aproximar como: $d \approx 2(1 - \rho)$
- Como el coeficiente de correlación oscila entre -1 y 1 , el estadístico DW se situara entre 0 y 4 , es decir:
 $0 \leq d \leq 4$
- En el mejor de los casos, $d = 2$, nos indicaría que **NO** habría problema de autocorrelación.

Autocorrelación: Durbin-Watson




H_0 = No hay autocorrelación (+)

H_0^* = No hay autocorrelación (-)

Como corregir ? ...





Autocorrelación: Corrección Método Cochrane-Orcutt

Realizar una **transformación** del modelo original con un **modelo de diferencias** teniendo en cuenta el parámetro de la correlación del residuo.

- Hallar el parámetro ρ .

$$\epsilon_t = \rho\epsilon_{t-1} + v_t$$

- Se aplica la transformación de **primeras diferencias**.

$$Y_t - \rho Y_{t-1} = \beta_0(1 - \rho) + \beta_1(X_t - \rho X_{t-1}) + \mu_t$$

- De esta forma ya se ha corregido el problema.

Autocorrelación: Corrección Método Cochrane-Orcutt

Vamos a tener un modelo de:

$$\text{Ventas}_t = \beta_0 + \beta_1 \text{inventarios}_t + \epsilon_t$$

Paso 1: Estimar el modelo

```
library(dynlm) # Modelo dinámico
library(orcutt) # Corrección Autocorrelación
base_da<-read_excel("regauto.xlsx")
reg.dyn<-dynlm(ventas~inventarios, data = base_da)
reg.dyn %>% broom::tidy()
```

term	estimate	std.error	statistic	p.value
(Intercept)	-903	1.17e+03	-0.775	0.443
inventarios	0.643	0.00289	223	1.72e-63

Autocorrelación: Corrección Método Cochrane-Orcutt

Paso 2: Hallar estadístico D-Watson

```
dwtest(reg.dyn)
```

```
#>  
#>      Durbin-Watson test  
#>  
#> data:  reg.dyn  
#> DW = 1.3743, p-value = 0.01175  
#> alternative hypothesis: true autocorrelation is greater than 0
```

Note que el estadístico DW, cae en la zona de **autocorrelación positiva**. Debemos proceder a su corrección

Autocorrelación: Corrección Método Cochrane-Orcutt

Paso 3: Corregir el problema

```
cochrane.orcutt(reg.dyn)
```

```
#> Cochrane-orcutt estimation for first order autocorrelation
#>
#> Call:
#> dynlm(formula = ventas ~ inventarios, data = base_da)
#>
#> number of interaction: 3
#> rho 0.311047
#>
#> Durbin-Watson statistic
#> (original): 1.37429 , p-value: 1.175e-02
#> (transformed): 2.04410 , p-value: 4.902e-01
#>
#> coefficients:
#> (Intercept) inventarios
#> -966.166560 0.642991
```

De tal manera que el modelo ya esta corregido

Autocorrelación: Corrección Método Cochrane-Orcutt

	(1)	(2)
(Intercept)	-902.827 (1165.121)	-966.167 (1673.581)
inventarios	0.643 *** (0.003)	0.643 *** (0.004)
N	42	42
R2	0.999	0.998
logLik	-414.513	
AIC	835.026	

*** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$.

Bibliografía

- ▣ Gujarati, D. N., & Porter, D. C. (2011). *Econometria Básica*. Ed. Porto Alegre: AMGH..
- ▣ Stock, J. H., Watson, M. W., & Larrión, R. S. (2012). *Introducción a la Econometría*.
- ▣ Wooldridge, J. M. (2015). *Introductory econometrics: A modern approach*. Cengage learning.

Gracias por su atención!

Carlos Andres Yanes Guerra

 cayanes@uninorte.edu.co

 [keynes37](https://twitter.com/keynes37)